

Materi Praktikum 2 Jam

OLS, Ridge, dan Lasso Regression

Mata Kuliah: Pengantar Sains Data

Deskripsi Praktikum

Praktikum ini dirancang untuk membantu mahasiswa memahami alur berpikir dalam pemodelan regresi, dimulai dari *use case*, kemudian *Ordinary Least Squares* (OLS) sebagai model dasar, lalu mengidentifikasi masalah OLS pada data dengan prediktor yang saling berkorelasi, dan akhirnya mempelajari bagaimana Ridge dan Lasso digunakan sebagai *shrinkage methods* untuk menghasilkan model yang lebih stabil dan lebih sederhana.

Capaian Pembelajaran

Setelah mengikuti praktikum ini, mahasiswa diharapkan mampu:

1. memahami *use case* prediksi hasil panen padi sebagai masalah regresi;
2. menjelaskan konsep dasar OLS;
3. mengidentifikasi permasalahan OLS pada data dengan multikolinearitas;
4. memahami ide dasar shrinkage pada Ridge dan Lasso;
5. membandingkan perilaku OLS, Ridge, dan Lasso melalui visualisasi dan metrik sederhana.

Use Case Praktikum

Sebuah tim data science di bidang pertanian ingin memprediksi hasil panen padi (*yield*) berdasarkan beberapa variabel lingkungan dan budidaya, yaitu:

- curah hujan (*rainfall*),
- kelembapan udara (*humidity*),
- temperatur,
- kelembapan tanah (*soil_moisture*),
- irigasi,
- pupuk A
- pupuk B,
- intensitas cahaya matahari,
- pH tanah,
- indeks hama.

Dalam data nyata, beberapa variabel tersebut saling berkaitan. Misalnya, curah hujan sering berhubungan dengan kelembapan udara dan kelembapan tanah, sedangkan pupuk A dan pupuk B dapat memiliki pola penggunaan yang mirip. Kondisi ini membuat pemodelan menjadi menarik karena kita perlu memahami kapan OLS cukup digunakan, dan kapan metode shrinkage seperti Ridge dan Lasso

menjadi lebih relevan.

Alokasi Waktu Praktikum (2 Jam)

Waktu Kegiatan

15 menit	Pengantar topik, penjelasan use case, dan tujuan praktikum
20 menit	Eksplorasi data dan visualisasi awal
20 menit	Implementasi OLS dan interpretasi hasil
20 menit	Analisis masalah OLS: korelasi fitur dan instabilitas koefisien
20 menit	Implementasi Ridge dan interpretasi hasil
15 menit	Implementasi Lasso dan interpretasi hasil
10 menit	Perbandingan ketiga model dan diskusi

Alur Konseptual Praktikum

Use Case → OLS → Masalah OLS → Shrinkage → Ridge / Lasso

Bagian 1 – Memahami Use Case

Pada bagian awal, dosen menjelaskan konteks masalah: kita tidak hanya ingin membandingkan model yang cocok pada data latih, tetapi juga model yang mampu memberikan prediksi yang baik pada data baru. Mahasiswa diminta memahami bahwa hasil panen padi dipengaruhi oleh banyak faktor, dan hubungan antar faktor tersebut tidak selalu berdiri sendiri.

Aktivitas mahasiswa:

- Mengidentifikasi target prediksi.
- Mengidentifikasi fitur yang digunakan.
- Menjelaskan secara singkat mengapa kasus ini termasuk masalah regresi.

Bagian 2 – Eksplorasi Data Awal

Mahasiswa melakukan eksplorasi sederhana terhadap dataset. Tujuan bagian ini adalah membangun intuisi bahwa sebelum memodelkan data, kita perlu memahami struktur data terlebih dahulu.

Aktivitas mahasiswa:

- Membaca dataset dengan Python.
- Menampilkan 5 baris pertama data.
- Melihat ringkasan statistik sederhana.
- Membuat scatter plot satu fitur terhadap target.
- Membuat heatmap korelasi untuk melihat hubungan antar fitur.

Bagian 3 – OLS sebagai Baseline

OLS adalah model regresi linear dasar yang mencari koefisien terbaik dengan cara meminimalkan jumlah kuadrat error:

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Dalam konteks ini, OLS mencoba mencari hubungan linear antara hasil panen padi dan seluruh variabel yang tersedia.

Bagian 4 – Permasalahan OLS

Pada data dengan fitur saling berkorelasi, OLS sering menghadapi masalah:

- koefisien bisa menjadi tidak stabil,
- perubahan kecil pada data dapat mengubah koefisien,
- interpretasi pengaruh setiap fitur menjadi sulit.

Bagian 5 – Mengapa Perlu Shrinkage?

Shrinkage menambahkan penalti agar koefisien tidak terlalu besar. Dengan demikian, model menjadi lebih stabil dan tidak terlalu sensitif terhadap data latih.

- Ridge: mengecilkan semua koefisien secara bertahap.
- Lasso: mengecilkan koefisien dan dapat membuat sebagian koefisien menjadi nol.

Contoh Kode Program Python

Berikut contoh kode Python sederhana yang dapat digunakan dalam praktikum. Dataset diasumsikan berada pada file `agri_shrinkage_train.csv`.

3

1. Import Library dan Membaca Data

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.pipeline import Pipeline

# membaca data
df = pd.read_csv("agri_shrinkage_train.csv")

print(df.head())
print(df.describe())
```


2. Memisahkan Fitur dan Target

```
X = df.drop(columns=["yield"])
y = df["yield"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42
)
```

3. Scatter Plot Sederhana


```
plt.figure(figsize=(6,4))
plt.scatter(df["rainfall"], df["yield"], alpha=0.7)
plt.xlabel("Rainfall")
plt.ylabel("Yield")
plt.title("Hubungan Rainfall terhadap Yield")
plt.show()
```



4. Heatmap Korelasi

```
corr = df.corr()

plt.figure(figsize=(8,6))
plt.imshow(corr, cmap="coolwarm", interpolation="nearest")
plt.colorbar()
plt.xticks(range(len(corr.columns)), corr.columns, rotation=45, ha="right")
plt.yticks(range(len(corr.columns)), corr.columns)
plt.title("Heatmap Korelasi")
plt.tight_layout()
plt.show()
```



5. OLS

```
ols_model = Pipeline([
    ("scaler", StandardScaler()),
    ("model", LinearRegression())
])

ols_model.fit(X_train, y_train)

y_pred_train_ols = ols_model.predict(X_train)
y_pred_test_ols = ols_model.predict(X_test)

rmse_train_ols = np.sqrt(mean_squared_error(y_train, y_pred_train_ols))
rmse_test_ols = np.sqrt(mean_squared_error(y_test, y_pred_test_ols))
r2_train_ols = r2_score(y_train, y_pred_train_ols)
r2_test_ols = r2_score(y_test, y_pred_test_ols)

print("OLS Train RMSE:", rmse_train_ols)
print("OLS Test RMSE :", rmse_test_ols)
print("OLS Train R2 :", r2_train_ols)
print("OLS Test R2 :", r2_test_ols)

coef_ols = ols_model.named_steps["model"].coef_
print("Koefisien OLS:", coef_ols)
```

```
OLS Train RMSE: 1.5303978430555065
OLS Test RMSE : 1.3882559748075445
OLS Train R2 : 0.9052198828822228
OLS Test R2 : 0.9261067913065398
Koefisien OLS: [ 2.28122011 -0.09933998  2.86331003 -0.90516941  1.23520123  1.20092633
 1.26978926  0.40073291 -0.72718195 -1.43304743]
```

6. Ridge

```

ridge_model = Pipeline([
    ("scaler", StandardScaler()),
    ("model", Ridge(alpha=5.0))
])

ridge_model.fit(X_train, y_train)

y_pred_train_ridge = ridge_model.predict(X_train)
y_pred_test_ridge = ridge_model.predict(X_test)

rmse_train_ridge = np.sqrt(mean_squared_error(y_train, y_pred_train_ridge))
rmse_test_ridge = np.sqrt(mean_squared_error(y_test, y_pred_test_ridge))
r2_train_ridge = r2_score(y_train, y_pred_train_ridge)
r2_test_ridge = r2_score(y_test, y_pred_test_ridge)

print("Ridge Train RMSE:", rmse_train_ridge)
print("Ridge Test RMSE :", rmse_test_ridge)
print("Ridge Train R2 :", r2_train_ridge)
print("Ridge Test R2 :", r2_test_ridge)

coef_ridge = ridge_model.named_steps["model"].coef_
print("Koefisien Ridge:", coef_ridge)

```

```

OLS Train RMSE: 1.5303978430555065
OLS Test RMSE : 1.3882559748075445
OLS Train R2 : 0.9052198828822228
OLS Test R2 : 0.9261067913065398
Koefisien OLS: [ 2.28122011 -0.09933998  2.86331003 -0.90516941  1.23520123  1.20092633
 1.26978926  0.40073291 -0.72718195 -1.43304743]

```

7. Lasso

```

lasso_model = Pipeline([
    ("scaler", StandardScaler()),
    ("model", Lasso(alpha=0.08, max_iter=20000))
])

lasso_model.fit(X_train, y_train)

y_pred_train_lasso = lasso_model.predict(X_train)
y_pred_test_lasso = lasso_model.predict(X_test)

rmse_train_lasso = np.sqrt(mean_squared_error(y_train, y_pred_train_lasso))
rmse_test_lasso = np.sqrt(mean_squared_error(y_test, y_pred_test_lasso))
r2_train_lasso = r2_score(y_train, y_pred_train_lasso)
r2_test_lasso = r2_score(y_test, y_pred_test_lasso)

print("Lasso Train RMSE:", rmse_train_lasso)
print("Lasso Test RMSE :", rmse_test_lasso)
print("Lasso Train R2 :", r2_train_lasso)
print("Lasso Test R2 :", r2_test_lasso)

coef_lasso = lasso_model.named_steps["model"].coef_
print("Koefisien Lasso:", coef_lasso)

```

```

Lasso Train RMSE: 1.588277239147155
Lasso Test RMSE : 1.3377821526060358
Lasso Train R2 : 0.8979151780351797
Lasso Test R2 : 0.9313822902725097
Koefisien Lasso: [ 1.28147841 -0.          2.82000133 -0.          1.17859724  1.91719868
 0.48717175  0.35204012 -0.70391729 -1.34422124]

```

8. Membandingkan Koefisien

```


features = X.columns

plt.figure(figsize=(10,5))
x = np.arange(len(features))
width = 0.25


plt.bar(x - width, coef_ols, width, label="OLS")
plt.bar(x, coef_ridge, width, label="Ridge")
plt.bar(x + width, coef_lasso, width, label="Lasso")


plt.axhline(0, color="black")
plt.xticks(x, features, rotation=45, ha="right")
plt.ylabel("Nilai Koefisien")
plt.title("Perbandingan Koefisien Model")
plt.legend()
plt.tight_layout()
plt.show()

```



Bonus:





Pertanyaan Fundamental

Mahasiswa diminta menjawab pertanyaan berikut selama atau setelah

praktikum: 6

1. Apa yang menjadi target prediksi pada use case ini?

Target prediksi pada use case ini adalah hasil panen padi (yield)

2. Mengapa kasus hasil panen padi termasuk masalah regresi?

Karena berupa nilai numerik dan sifatnya kontinu yang dapat dihitung

3. Apa makna koefisien positif dan negatif dalam model regresi?

- Positif = Jika nilai fitur meningkat, maka hasil prediksi yield juga cenderung meningkat
- Negatif = Jika nilai fitur meningkat, maka hasil prediksi yield cenderung menurun
-

4. Mengapa kita tidak cukup hanya melihat nilai prediksi tanpa memahami struktur data?

Karena struktur data dapat mempengaruhi kualitas model

5. Apa yang dimaksud dengan multikolinearitas?

Multikolinearitas adalah kondisi ketika beberapa fitur saling berkorelasi kuat satu sama lain

6. Mengapa multikolinearitas dapat menimbulkan masalah bagi OLS?
Karena sulit menentukan pengaruh masing-masing fitur secara jelas jika fitur tersebut mirip

7. Mengapa OLS tetap penting dipelajari meskipun memiliki kelemahan?
Karena dasar dari banyak metode regresi lainnya

8. Apa ide utama shrinkage dalam Ridge dan Lasso?
Memberikan penalti atau nilai toleransi pada besar koefisien agar model lebih stabil, tidak terlalu sensitif dan tidak overfitting

9. Apa perbedaan utama Ridge dan Lasso dari sisi perilaku koefisien?

- Ridge = mengecilkan semua koefisien secara bertahap dan jarang membuatnya menjadi 0
- Lasso = mengecilkan koefisien dan dapat membuatnya menjadi 0 dan secara otomatis menghapus fitur yang kurang penting

10. Mengapa Lasso sering dikaitkan dengan *feature selection*?
Karena dapat membuat beberapa koefisien menjadi 0

Pertanyaan Analisis

Mahasiswa juga diminta melakukan analisis terhadap hasil eksperimen:

1. Dari heatmap korelasi, fitur mana yang tampak saling berkorelasi?

- rainfall
- humidity,
- soil_moisture,
- fertilizer_A dengan fertilizer_B.

2. Apakah koefisien OLS tampak stabil dan mudah diinterpretasikan?
tidak selalu stabil ketika terdapat multikolinearitas sehingga akan sulit dibandingkan dengan Ridge dan Lasso

3. Bandingkan besar koefisien OLS dan Ridge. Apa yang berubah?
Ridge

- Nilai koefisien menjadi lebih kecil
- Lebih stabil
- Tidak terlalu ekstrem

4. Apakah ada koefisien Lasso yang menjadi nol atau sangat kecil? Apa artinya?
Ada, terdapat pada beberapa koefisien yang menjadi sangat kecil bahkan hingga 0. Artinya fitur dianggap tidak penting sehingga kontribusinya di hilangkan.

5. Model mana yang memberikan performa terbaik pada data uji berdasarkan RMSE dan R^2 ?

Model yang terbaik adalah yang memiliki RMSE yang kecil dan R^2 yang paling besar, sehingga Ridge yang lebih baik

6. Jika tujuan utama adalah stabilitas prediksi, model mana yang lebih masuk akal?

Ridge, karena lebih stabil terhadap multikolinearitas dan koefisien yang tidak terlalu ekstrem

7. Jika tujuan utama adalah menyederhanakan model, model mana yang lebih tepat?

Lasso, karena dapat menghilangkan fitur yang tidak berpengaruh secara signifikan sehingga menghasilkan model yang lebih sederhana

8. Apakah model dengan error terkecil selalu menjadi model terbaik untuk dipilih? Jelaskan.

Tidak, selain Error ada hal yang harus di pertimbangkan seperti, Stabilitas dari model, Interpretasinya, dan kompleksitas model itu sendiri

Tugas Singkat di Akhir Praktikum

Sebagai penutup, mahasiswa diminta menuliskan refleksi singkat (1–2 paragraf) mengenai:

- pelajaran utama yang diperoleh dari perbandingan OLS, Ridge, dan Lasso;
- alasan mengapa shrinkage penting dalam sains data;
- model mana yang menurut mereka paling sesuai untuk use case hasil panen padi dan alasannya.

7

Luaran Praktikum

Pada akhir sesi, mahasiswa diharapkan menghasilkan:

1. notebook atau file Python yang dapat dijalankan;
2. visualisasi dasar: scatter plot, heatmap korelasi, dan perbandingan koefisien;
3. jawaban atas pertanyaan fundamental dan analisis;
4. refleksi singkat mengenai hasil praktikum.

Penutup

Praktikum ini menekankan bahwa pemodelan tidak berhenti pada “membangun model”. Mahasiswa perlu memahami konteks masalah, mengenali keterbatasan model dasar seperti OLS, dan memahami kapan metode seperti Ridge dan Lasso menjadi penting. Dengan demikian, mahasiswa tidak hanya belajar menjalankan algoritma, tetapi juga belajar berpikir sebagai seorang analis data.