

1.4.1. Data Understanding

- Load dataset CSV

```
import numpy as np
import pandas as pd
df = pd.read_csv('paddy_productivity_scenario.csv')
df.head(10)
```

- Tampilkan struktur data

Farm_id	region	season	irrigation	soil_quality	rice_variety	rainfall_mm	temperature_c	humidity_pct	fertilizer_kg_ha	pesticide_l_ha	land_area_ha	planting_density	yield_ton_ha	risk_category
0 FARM_225	Dataran Rendah	Musim Kemarau	Teknis	Sedang	Varietas C	123.65	26.24	61.71	90.91	0.85	1.77	24.70	7.52	Risiko Rendah
1 FARM_043	Dataran Rendah	Musim Hujan	Teknis	Tinggi	Varietas B	179.52	27.05	80.64	61.03	2.61	1.72	26.28	7.67	Risiko Rendah
2 FARM_286	Dataran Rendah	Musim Kemarau	Semi Teknis	Rendah	Varietas A	118.41	25.24	68.18	NaN	2.54	0.88	26.21	5.83	Risiko Rendah
3 FARM_303	Dataran Menengah	Musim Kemarau	Tadah Hujan	Tinggi	Varietas B	193.10	25.04	56.90	108.04	2.43	2.08	26.65	7.07	Risiko Rendah
4 FARM_057	Dataran Rendah	Musim Hujan	Teknis	Tinggi	Varietas B	314.36	26.12	83.94	107.33	1.71	1.08	16.56	6.03	Risiko Rendah
5 FARM_273	Tadah Hujan	Musim Hujan	Teknis	Sedang	Varietas B	193.83	25.95	83.35	148.52	3.84	3.52	22.07	8.94	Risiko Rendah
6 FARM_016	Dataran Rendah	Musim Hujan	Tadah Hujan	Rendah	Varietas C	368.09	23.86	85.39	103.44	0.20	0.63	22.06	0.91	Risiko Tinggi
7 FARM_050	Dataran Rendah	Musim Hujan	Semi Teknis	Sedang	Varietas B	208.95	27.82	72.62	108.19	0.97	1.65	24.18	7.13	Risiko Rendah
8 FARM_249	Tadah Hujan	Musim Hujan	Semi Teknis	Sedang	Varietas B	210.44	27.55	78.04	104.12	1.75	1.17	27.39	7.44	Risiko Rendah
9 FARM_125	Dataran Rendah	Musim Kemarau	Teknis	Sedang	Varietas C	58.80	25.67	77.13	103.12	2.24	1.27	17.95	6.08	Risiko Rendah

- Identifikasi:

- tipe data (numerik / kategorikal)
- missing values

Pertanyaan Konseptual:

1. Apa perbedaan penanganan fitur numerik dan kategorikal?
 - Numerik : Data berbentuk angka yang dapat di hitung secara matematis
 - Kategorik : Data berbentuk label atau kategori yang tidak dapat langsung di gunakan dalam perhitungan, sehingga perlu di ubah ke bentuk melalui encoding
2. Mengapa missing value tidak boleh diabaikan?


karena dapat menyebabkan model belajar dari data yang tidak lengkap, sehingga menghasilkan prediksi yang bias atau tidak akurat. Selain itu, beberapa algoritma machine learning tidak dapat berjalan jika terdapat missing value

1.4.2. Exploratory Data Analysis (EDA) Lakukan minimal:

- Histogram (distribusi)


```
import matplotlib.pyplot as plt

plt.hist(df["rainfall_mm"], bins=20)
plt.title("Distribusi Curah Hujan")
plt.xlabel("Rainfall")
plt.ylabel("Frekuensi")
plt.show()
```



- Scatter plot (relasi)


```
plt.scatter(df["rainfall_mm"],
df["yield_ton_ha"])
plt.title("Distribusi Curah Hujan")
plt.xlabel("Rainfall")
```



```
plt.ylabel("Frekuensi")
plt.show()
```


- Boxplot (outlier)

```
plt.boxplot(df["yield_ton_ha"])
plt.title("Boxplot Yield")
plt.show()
```



- Analisis kategorikal (bar chart)

```
df["season"].value_counts().plot(kind="bar")
plt.title("Distribusi Musim")
plt.show()
```



Wajib:

- Interpretasi setiap visualisasi
- Hubungkan dengan konteks pertanian

Pertanyaan Konseptual:

1. Apakah hubungan curah hujan dan hasil panen linear?

Tidak sepenuhnya linear, terdapat titik optimal curah hujan. Jika terlalu rendah atau terlalu tinggi, hasil panen justru menurun

2. Apa dampak musim terhadap hasil panen?

Musim hujan dapat meningkatkan hasil jika dalam batas optimal, namun jika berlebihan dapat menyebabkan kerusakan tanaman

3. Apakah semua outlier harus dihapus?

Tidak, perlu dianalisis terlebih dahulu sebelum dihapus

1.4.3. Data Cleaning

Sebelum :

```
farm_id      0
region       0
season       0
irrigation   0
soil_quality 5
rice_variety 0
rainfall_mm  8
temperature_c 6
humidity_pct 0
fertilizer_kg_ha 7
pesticide_l_ha 0
land_area_ha 0
planting_density 0
yield_ton_ha 0
risk_category 0
dtype: int64
```

- Untuk Numerik

```
df["rainfall_mm"] =
df["rainfall_mm"].fillna(df["rainfall_mm"].median())
df["temperature_c"] =
df["temperature_c"].fillna(df["temperature_c"].median())
df["fertilizer_kg_ha"] =
df["fertilizer_kg_ha"].fillna(df["fertilizer_kg_ha"].median())
```

Ketika Data yang di gunakan adalah Numerik maka dapat menggunakan mean

- Dan untuk Kategorik

```
df["season"] = df["season"].fillna(df["season"].mode()[0])
df["region"] = df["region"].fillna(df["region"].mode()[0])
```

namun ketika datanya adalah kategorik, dapat di isi dengan mode

- Tangani missing values

Sesudah :

```
farm_id      0
region       0
season       0
irrigation   0
soil_quality 0
rice_variety 0
rainfall_mm  0
temperature_c 0
humidity_pct 0
fertilizer_kg_ha 0
pesticide_l_ha 0
land_area_ha 0
planting_density 0
yield_ton_ha 0
risk_category 0
dtype: int64
```

Sehingga dapat di lihat, sudah tidak ada lagi missing value yang ada di dalamnya,

- Jelaskan metode yang digunakan:
 - mean / median / mode / drop
 - Numerik :

Missing value pada fitur numerik seperti rainfall, temperature, dan fertilizer dapat menggunakan metode median agar distribusi data tetap lebih representatif dan tidak menyebabkan distorsi yang signifikan pada model

- Kategorik :

Missing value pada fitur kategorikal seperti season dan region ditangani menggunakan mode, atau nilai yang paling sering muncul, hal ini membantu model tetap belajar dari pola yang realistis.

Pertanyaan:

1. Apa risiko jika missing value ditangani secara sembarangan?

Missing value yang ditangani secara sembarangan dapat menyebabkan distorsi pada data, sehingga model machine learning belajar pola yang tidak sesuai dengan kondisi sebenarnya.

1.4.4. Feature Engineering

- Buat minimal 2 fitur baru

Sebelum : `df.shape` = (355, 15)

- Rainfall-squared

```
df["rainfall_squared"] = df["rainfall_mm"] ** 2
```

untuk menangkap hubungan non-linear antara curah hujan dan hasil panen. Dari hasil scatter plot pada tahap EDA, terlihat bahwa hubungan antara rainfall dan yield tidak berbentuk linear, melainkan memiliki titik optimal.

- Rainfall-deviation

```
df["rainfall_deviation"] = abs(df["rainfall_mm"] -
df["rainfall_mm"].mean())
```

untuk mengukur seberapa jauh nilai curah hujan dari kondisi rata-rata.

- Fertilizer-efficiency

```
df["fertilizer_efficiency"] = df["fertilizer_kg_ha"] /
df["rainfall_mm"]
```

Sesudah : `df.shape` = (355, 18)

membantu model memahami efisiensi penggunaan pupuk dalam kondisi lingkungan tertentu, sehingga memberikan informasi tambahan yang tidak terlihat dari fitur tunggal.

- Lakukan encoding untuk fitur kategorikal

```
df = pd.get_dummies(df, columns=["season", "region"],
drop_first=True)
```

menggunakan one-hot encoding untuk mengubah data kategorikal menjadi numerik tanpa memberikan asumsi urutan antar kategori, sehingga model dapat memahami perbedaan kategori secara tepat.

Contoh:

- rainfall squared
- fertilizer per area

Wajib:

- Jelaskan alasan setiap fitur baru
- Hubungkan dengan hasil EDA

Berdasarkan EDA, fitur kategorikal seperti season memiliki pengaruh terhadap hasil panen. Oleh karena itu, dilakukan encoding agar informasi tersebut dapat digunakan dalam model tanpa mengubah makna kategorinya.

1.4.5. Supervised Learning

- Gunakan Linear Regression atau model lain
- Target: `yield_ton_ha`


Wajib:

- Evaluasi model (MAE / RMSE)

```
from sklearn.metrics import mean_absolute_error, mean_squared_error
import numpy as np
mae = mean_absolute_error(y, y_pred)
rmse = np.sqrt(mean_squared_error(y, y_pred))
print("MAE:", mae)
print("RMSE:", rmse)
```

```
MAE: 0.8252750425648336
RMSE: 1.1105367626003058
```

- Visualisasi actual vs predicted



Pertanyaan:

1. Dimana model gagal?

cenderung gagal pada data dengan nilai outlier, seperti hasil panen yang sangat rendah atau sangat tinggi. Hal ini disebabkan karena model linear regression memiliki keterbatasan dalam menangkap pola yang kompleks, terutama pada kondisi yang tidak umum.

2. Apakah model dapat menangkap pola non-linear?

Karena hanya mampu menangkap hubungan linear antar variabel

1.4.6. Unsupervised Learning

- Gunakan KMeans clustering

```
kmeans = KMeans(n_clusters=3, random_state=42)
df["cluster"] = kmeans.fit_predict(X_cluster)
```

- Tentukan jumlah cluster dengan Elbow Method

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt


inertia = []
K = range(1, 6)

for k in K:
    kmeans = KMeans(n_clusters=k, random_state=42)
    kmeans.fit(X_cluster)
    inertia.append(kmeans.inertia_)

plt.plot(K, inertia, marker='o')
plt.title("Elbow Method")
plt.xlabel("Number of Clusters")
plt.ylabel("Inertia")
plt.show()
```

Wajib:

- Visualisasi cluster



- Interpretasi setiap cluster
 - Cluster 0 menunjukkan kondisi dengan curah hujan rendah dan penggunaan pupuk rendah, yang kemungkinan memiliki produktivitas rendah.
 - Cluster 1 menunjukkan kondisi optimal dengan curah hujan dan pupuk yang seimbang.
 - Cluster 2 menunjukkan curah hujan tinggi namun tidak diimbangi dengan pupuk yang cukup.

Pertanyaan:

1. Apakah cluster sesuai dengan kondisi nyata?

Ya, cluster yang terbentuk merepresentasikan kondisi yang masuk akal dalam konteks pertanian, seperti perbedaan antara kondisi optimal, kekurangan pupuk, dan kelebihan curah hujan

2. Bagaimana cluster membantu pengambilan keputusan?

membantu dalam pengambilan keputusan seperti menentukan strategi penggunaan pupuk, pengelolaan irigasi, serta identifikasi wilayah dengan risiko rendah atau tinggi terhadap kegagalan panen

1.4.7. Analisis dan Insight

Tuliskan minimal 5 insight penting dari hasil analisis.

- Curah hujan terlalu tinggi menurunkan hasil panen
- Curah hujan terlalu rendah juga mengurangi produktivitas
- Penggunaan pupuk yang optimal meningkatkan hasil panen
- Efisiensi pupuk lebih penting daripada jumlah pupuk
- Perbedaan musim mempengaruhi hasil panen
- Beberapa kondisi ekstrem menyebabkan gagal panen
- Data dapat dikelompokkan menjadi kondisi optimal dan tidak optimal

1.4.8. Refleksi

Jawab pertanyaan berikut:

1. Apa peran EDA dalam seluruh pipeline?

EDA berperan sebagai dasar dalam memahami karakteristik data sebelum dilakukan modeling. Melalui EDA, dapat diketahui pola, distribusi, serta hubungan antar variabel yang kemudian digunakan sebagai acuan dalam data cleaning dan feature engineering

2. Apa yang terjadi jika EDA dilewati?

Jika EDA dilewati, model akan dibangun tanpa pemahaman terhadap data, sehingga berisiko menghasilkan prediksi yang tidak akurat. Selain itu, kesalahan dalam data seperti outlier atau hubungan non-linear tidak akan terdeteksi

3. Apakah model terbaik selalu yang paling kompleks?

Tidak. Model terbaik adalah model yang paling sesuai dengan data dan mampu memberikan hasil yang akurat serta mudah diinterpretasikan. Model yang terlalu kompleks justru dapat menyebabkan overfitting dan sulit digunakan dalam praktik

4. Bagaimana model ini dapat digunakan dalam dunia nyata?

Model ini dapat digunakan untuk membantu petani atau pengambil kebijakan dalam memprediksi hasil panen berdasarkan kondisi lingkungan dan penggunaan pupuk.