

Tugas 1 Minggu
OLS, Ridge, dan Lasso Regression

Bagian A – Memahami Use Case

Jelaskan secara singkat:

- a. apa target prediksi dalam kasus ini;

Memprediksi hasil panen padi (*yield*) dengan menggunakan variable variable yang telah diketahui.

- b. apa saja prediktor yang digunakan;

- rainfall
- humidity
- temperature
- soil_moisture
- irrigation
- fertilizer_A
- fertilizer_B
- sunlight
- soil_pH
- pest_index

- c. mengapa kasus ini relevan untuk regresi;

karena target yang diprediksi berupa nilai numerik kontinu yaitu jumlah hasil panen padi

- d. mengapa mungkin muncul masalah ketika banyak variabel digunakan secara bersamaan.

Karena beberapa variabel dapat saling berkorelasi sehingga model OLS menjadi tidak stabil.

Bagian B – Memahami OLS

Lakukan hal berikut:

- a. Jelaskan apa itu OLS dengan bahasa sederhana.

Ordinary Least Squares) adalah metode yang mencari garis terbaik dengan meminimalkan jumlah kuadrat error antara nilai prediksi dan nilai aktual.


- b. Tuliskan bentuk umum model regresi linear:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

- c. Jelaskan arti koefisien dalam konteks hasil panen padi.

Koefisien menunjukkan pengaruh suatu variable terhadap hasil panen, misalnya koefisien rainfall terbesar 2.5 berarti setiap kenaikan rainfall sebesar 1 unit di perkirakan meningkatkan yield sebesar 2.5 unit, dengan asumsi variable lain tetap.

- d. Buat satu visualisasi sederhana yang menunjukkan hubungan antara satu fitur dengan target, misalnya *rainfall* terhadap *yield*.




Evaluasi OLS setelah training dan testing

```
0.031226830999439008  
0.03448484155679251  
0.9987944848559555  
0.9979517128723636
```

Bagian C – Mengidentifikasi Permasalahan OLS

Analisis data dan jelaskan:

- a. apakah ada fitur yang saling berkorelasi;




Terdapat beberapa fitur yang saling berkorelasi cukup tinggi (Berwarna merah), seperti rainfall dengan humidity dan soil_moisture. Hal ini menunjukkan adanya multikolinearitas.

b. bagaimana korelasi antar fitur dapat memengaruhi OLS;

Terdapat beberapa fitur yang saling berkorelasi cukup tinggi, seperti rainfall dengan humidity dan soil_moisture. Hal ini menunjukkan adanya multikolinearitas.

c. mengapa koefisien OLS bisa menjadi tidak stabil;




karena adanya multikolinearitas antar fitur. Ketika dua variabel memiliki informasi yang mirip, model kesulitan menentukan variabel mana yang sebenarnya paling berpengaruh terhadap target


d. mengapa model yang terlalu bebas dapat menyebabkan generalisasi kurang baik.

Gunakan minimal dua visualisasi berikut:

- heatmap korelasi fitur;




- grafik koefisien OLS;



- visualisasi instabilitas koefisien (misalnya melalui bootstrap atau resampling)

sederhana).



Bagian D – Ridge Regression

Lakukan analisis Ridge dan jelaskan:

a. ide dasar penalti L_2 ;

pengembangan dari OLS yang menambahkan penalti terhadap besar koefisien model, agar mengurangi koefisien yang terlalu besar, meningkatkan stabilitas model, dan mengurangi dampak multikolinearitas.

b. bagaimana Ridge memengaruhi besar koefisien;

Dengan mengecilkan nilai koefisien tanpa menghilangkannya menjadi nol, sehingga pengaruhnya adalah fitur yang teteap akan di pertahankan, tetapi tidak menjadi terlalu ekstrim

c. mengapa Ridge cocok ketika banyak fitur sama-sama relevan;

masih memiliki kontribusi terhadap target. Pada kasus hasil panen padi, banyak variabel lingkungan saling berkaitan dan tetap penting dalam prediksi. Dengan membantu menstabilkan pengaruh variable tanpa membuang informasi penting

d. apa pengaruh Ridge terhadap stabilitas model.

Sertakan:

- satu visualisasi koefisien Ridge atau *coefficient path* Ridge;
- perbandingan koefisien OLS vs Ridge.

Bagian E – Lasso Regression

Lakukan analisis Lasso dan jelaskan:

a. ide dasar penalti L_1 ;

Lasso Regression adalah metode regresi yang menambahkan penalti terhadap jumlah absolut koefisien regresi.

b. bagaimana Lasso dapat membuat sebagian koefisien menjadi nol;

Dengan di berikannya penalti, model dapat merenggang dengan koefisiennya menjadi lebih sedikit, bahkan hingga nol


c. mengapa Lasso dapat dipandang sebagai metode *feature selection*;

Karena dengan metode Lasso, beberapa nilai koefisien yang tidak penting dapat di toleransi dengan diberikannya penalti

d. apa kelebihan Lasso dibanding OLS dalam kasus ini.

Sertakan:

- satu visualisasi *coefficient path* Lasso;



- bukti bahwa beberapa koefisien dapat menjadi nol atau mendekati nol.

```

rainfall      0.000000
humidity      0.000000
temperature   -0.008888
soil_moisture  0.442323
irrigation     0.000000
fertilizer_A  0.000000
fertilizer_B  0.000000
sunlight_intensity -0.000000
soil_pH        0.000000
pest_index    -0.348676
dtype: float64

```

Bagian F – Perbandingan dan Interpretasi

Bandungkan OLS, Ridge, dan Lasso dari aspek berikut:

a. stabilitas koefisien;

OLS - stabilitas koefisien yang paling rendah ketika terdapat multikolinearitas

Ridge - lebih stabil karena menggunakan penalti L2 yang mengecilkan koefisien

Lasso - meningkatkan stabilitas model dengan mengurangi kompleksitas dan menghapus fitur yang kurang relevan

b. kesederhanaan model;

OLS - menggunakan seluruh fitur tanpa pembatasan

Ridge - menggunakan seluruh fitur namun tetapi dengan koefisien yang lebih kecil

Lasso - paling sederhana karena beberapa fitur dapat dihapus secara otomatis melalui feature selection

c. interpretabilitas;

OLS - mudah dipahami, namun interpretasi dapat terganggu ketika terjadi multikolinearitas

Ridge - sedikit lebih sulit diinterpretasikan karena koefisien mengalami shrinkage

Lasso - lebih mudah diinterpretasikan karena hanya mempertahankan fitur-fitur penting

d. potensi generalisasi;

OLS - lebih rentan mengalami overfitting

Ridge & Lasso - kemampuan generalisasi yang lebih baik karena menggunakan regularisasi untuk mengurangi kompleksitas model

e. performa prediksi.

OLS - dapat dibandingkan menggunakan RMSE dan R^2 pada data testing

Ridge & Lasso - menghasilkan RMSE lebih kecil dibandingkan OLS, maka regularisasi berhasil meningkatkan performa model

Buat tabel ringkas yang memuat:

Model RMSE Train RMSE Test R^2 Train R^2 Test

	Model	RMSE Train	RMSE Test	R^2 Train	R^2 Test
0	OLS	0.031227	0.034485	0.998794	0.997952
1	Ridge	0.043373	0.038241	0.997674	0.997481
2	Lasso	0.107280	0.096245	0.985772	0.984045

Pertanyaan Analitis

Jawab pertanyaan berikut secara naratif:

1. Mengapa OLS masih penting dipelajari meskipun memiliki kelemahan?

Karena merupakan dasar utama dari metode regresi linear, sehingga membantu memahami bagaimana hubungan antara dua variabel input dan target yang dibentuk melalui model sederhana, selain itu Ridge dan Lasso sebenarnya merupakan pengembangan dari OLS

2. Apa masalah utama OLS pada data dengan multikolinearitas?

Ketidakstabilan koefisien regresi

3. Dalam kasus hasil panen padi, kapan Ridge lebih tepat digunakan?

Ridge Regression lebih tepat digunakan ketika sebagian besar fitur masih dianggap penting dan memiliki kontribusi terhadap hasil panen padi

4. Dalam kasus hasil panen padi, kapan Lasso lebih tepat digunakan?

Lasso Regression lebih tepat digunakan ketika ingin menyederhanakan model dan memilih fitur yang paling penting

5. Menurut Anda, model mana yang paling masuk akal untuk kasus ini? Jelaskan alasannya.

Ridge Regression merupakan model yang paling masuk akal untuk kasus prediksi hasil panen padi, karena dengan Lasso, khawatir di kedepannya model malah menghilangkan fitur yang sebenarnya cukup penting dalam panen padi.

Luaran yang Harus Dikumpulkan

Mahasiswa wajib mengumpulkan:

1. Laporan PDF berisi penjelasan, hasil analisis, visualisasi, dan interpretasi.
2. Kode Python (.py atau .ipynb) yang dapat dijalankan.
3. Dataset yang digunakan jika melakukan modifikasi atau pembuatan data sintetis.

Ketentuan Teknis

- Gunakan Python.
- Boleh menggunakan library seperti pandas, matplotlib, numpy, dan scikit-learn.
- Semua visualisasi harus diberi judul dan keterangan singkat.
- Interpretasi harus ditulis dengan bahasa sendiri, bukan hanya menampilkan output.

Rubrik Penilaian

Komponen Penilaian Bobot

Pemahaman use case dan OLS 15%

Identifikasi masalah OLS 20%

Implementasi Ridge 15%
Implementasi Lasso 15%
Visualisasi dan kualitas analisis 15%
Perbandingan kritis antar model 10%
Kerapian laporan dan kode 10%

Catatan untuk Mahasiswa

Tugas ini tidak hanya menilai apakah Anda bisa menjalankan model, tetapi juga apakah Anda memahami mengapa suatu model digunakan. Fokus utama tugas adalah membangun alur berpikir:

Use Case → OLS → Masalah OLS → Shrinkage → Ridge/Lasso